A low-angle, upward-looking photograph of several modern skyscrapers reaching towards a blue sky with scattered white clouds. A commercial airplane is visible in the sky, flying between the buildings. The perspective creates a sense of height and scale.

Chapter 3

Distance Metrics

- 1. Motivation
- 2. A Correlation-Based Metric
- 3. Marginal and Joint Entropy
- 4. Conditional Entropy
- 5. Kullback-Leibler Divergence
- 6. Cross-Entropy
- 7. Mutual Information
- 8. Variation of Information
- 9. Discretization
- 10. Distance Between Two Partitions
- 11. Experimental Results

Motivation

- 2장에서는 Correlation matrix에 대해서 확인
 - 하지만 Correlation은 codependence를 측정하는데 있어 중요한 단점을 지니고 있음
- 정보이론을 통해 이를 해결
 - 정보이론의 핵심은 확률변수와 연계된 불확실성을 계량화하는데 있음
- 머신러닝은 불확실성과 연계되어 있음
 - 머신러닝의 목적은 문제 상황의 해결책에 내재한 불확실성을 줄여가는데 있기 때문이다
- 본 장의 목적
 - 1. 의사결정나무의 목적함수 설정
 - 2. 분류 문제의 loss function 설정
 - 3. 두 확률변수의 거리 계산
 - 4. 클러스터 비교
 - 5. 특징 추출

A Correlation-Based Metric

- 상관관계는 선형 관계를 표상하는데 적절한 기준임
- 상관관계 행렬이 denoised되고 detoned된다면, 시스템 내의 정보 구조를 보여주는데 적합함
 - 서로 높은 상관관계가 있는 클러스터를 발견하는데 상관관계를 이용할 수 있음
- 하지만 correlation은 척도가 될 수 없다
 - Nonnegativity와 삼각부등식 조건을 만족하지 않기 때문
 - $|x + y| \leq |x| + |y| \quad \forall x, y \in R$

A Correlation-Based Metric

- Metric
 - $d : X \times X \rightarrow [0, \infty]$
 - 특성
 - $d(x, y) = 0 \leftrightarrow x = y$
 - $d(x, y) = d(y, x)$
 - $d(x, y) + d(y, z) \geq d(x, z)$

A Correlation-Based Metric

- 유클리드 거리 계산

- $d_\rho[X, Y] = \sqrt{\frac{1}{2}(1 - \rho[X, Y])}$

- $d[X, Y] = \sqrt{\sum (X_t - Y_t)^2}$

- $x = \frac{X - \bar{X}}{\sigma[X]}, y = \frac{Y - \bar{Y}}{\sigma[Y]}$

- $d[x, y] = \sqrt{\sum (x_t - y_t)^2} = \sqrt{\sum x_t^2 + \sum y_t^2 - 2 \sum x_t y_t} = \sqrt{T + T - 2T\sigma[x, y]} = \sqrt{2T(1 - \rho[x, y])} = \sqrt{4T}d_\rho[X, Y]$

- $\rho[X, Y] \in [-1, 1] \rightarrow d_\rho[X, Y] \in [0, 1]$

Marginal and Joint Entropy

- 상관관계
 - 두 확률변수의 선형 관계 포착
 - 비선형 관계는 포착하지 않음
- Outlier에 민감함
- 다변량 정규분포가 아닌 경우에 효용성을 입증하기 힘들
 - 두 변수간의 상관관계는 이변량 정규분포를 가정함

Marginal and Joint Entropy

- 엔트로피
 - 수식
 - $H[x] = -\sum_{x \in S_x} p[x] \log[p[x]]$
 - $0 \log[0] = 0$
 - $\lim_{p \rightarrow 0^+} p \log[p] = 0$
 - Entropy는 놀라운 값의 기댓값
 - $\frac{1}{p[x]}$: 관측값이 얼마나 놀라운 결과인지 측정
 - 확률이 낮을수록 놀라운 결과이기 때문
 - \log 함수는 $p[x]$ 가 $\frac{1}{p[x]}$ 상쇄하는 것 막음
 - 모든 결과값이 하나의 값으로 통일될 때 가장 낮으며, X 가 균등분포일 때 가장 높다
 - $p[x] = \frac{1}{|S_X|} \rightarrow \log[|S_X|]$

Conditional Entropy

- 엔트로피
 - 공동 엔트로피
 - $H[X, Y] = -\sum p[x, y] \log [p[x, y]]$
 - $H[X, Y] = H[Y, X], H[X, X] = H[X], H[X, Y] \geq \max\{H[X], H[Y]\}, H[X, Y] \leq H[X] + H[Y]$
 - 조건부 엔트로피
 - $H[X|Y] = H[X, Y] - H[Y] = -\sum p[y] \sum p[x|Y=y] \log [p[x|Y=y]]$
 - Y 정보를 알게 되었을 때의 X 예상에 대한 불확실성
 - $H[X|X] = 0, H[X] \geq H[X|Y]$

KullBack-Leibler Divergence

- 특징
 - p 와 q 가 같은 확률 공간 상의 서로 다른 확률 분포
 - $D_{KL}[p||q] = -p[x]\log \sum \left[\frac{q[x]}{p[x]} \right] = p[x]\log \sum \left[\frac{p[x]}{q[x]} \right]$
 - p 가 참고 분포 q 로부터 얼마나 떨어져 있는지에 대한 측정
 - 측도가 아님
 - Nonnegative 만족 ($D_{KL}[p||q] \geq 0$)
 - Symmetry 만족 못함 ($D_{KL}[p||q] \neq D_{KL}[q||p]$)
 - Triangle Inequality 만족 못함
- 비교
 - Joint entropy의 경우 같은 확률 공간 하에 있지 않아도 되지만, KLD는 같은 공간 하에 존재해야 한다.

Cross-Entropy

- Cross Entropy

- 수식

- $H_C[p||q] = -\sum p[x] \log[q[x]] = H[x] + D_{KL}[p||q]$

- 해석

- X 와 연계된 불확실성

- 참 분포 p 대신 잘못된 분포 q 를 활용하여 측정

- 특징

- 분류 문제에서 자주 사용하는 척도

- 금융 영역에서 의미가 깊음

Mutual Information

- 수식

- $$I[X, Y] = H[X] - H[X|Y] = H[X] + H[Y] - H[X, Y] = \sum \sum p[x, y] \log \left[\frac{p[x, y]}{p[x]p[y]} \right]$$

- $$D_{KL}[p[x, y] || p[x]p[y]] = \sum p[y] \sum p[x|y] \log \left[\frac{p[x|y]}{p[x]} \right]$$

- $$E_Y[D_{KL}[p[x|y] || p[x]]] = \sum p[x] \sum p[y|x] \log \left[\frac{p[y|x]}{p[y]} \right]$$

- $$E_X[D_{KL}[p[y|x] || p[y]]]$$

- 해석

- Y를 알게 되면서 줄어드는 X에 대한 불확실성

Mutual Information

- 수식
 - $I[X, Y] \geq 0, I[X, Y] = I[Y, X], I[X, X] = H[X]$
- 특징
 - 독립일 경우
 - $p[x, y] = p[x]p[y]$
 - $I[X, Y] = 0$
 - Metric 아님
 - $I[X, Z] \not\leq I[X, Y] + I[Y, Z]$

Variation of information

- 수식
 - $VI[X, Y] = H[X|Y] + H[Y|X] = H[X] + H[Y] - 2I[X, Y]$
 - $= 2H[X, Y] - H[X] - H[Y] = H[X, Y] - I[X, Y]$
- 범위
 - Lower bound
 - $VI[X, Y] = 0 \leftrightarrow X = Y$
 - Upper bound
 - $VI[X, Y] \leq H[X, Y]$
- 특징
 - Metric
- 대안
 - Bound Metric
 - $\widetilde{VI}[X, Y] = \frac{\max\{H[X|Y], H[Y|X]\}}{\max\{H[X], H[Y]\}} = 1 - \frac{I[X, Y]}{\max\{H[X], H[Y]\}}$

Discretization

- 수식

- $H[X] = - \int$




Figure 3.1 Correspondence between joint entropy, marginal entropies, conditional entropies, mutual information, and variation of information.

A low-angle, upward-looking photograph of several modern skyscrapers reaching towards a bright blue sky with scattered white clouds. In the center of the frame, a white commercial airplane is seen flying upwards. The perspective creates a sense of height and grandeur.

Thank you